Aprendizaje federado para mejorar la capacidad de detección de los sistemas de detección de intrusiones en redes IoT de borde

Carlos Ccama
Facultad de Ingeniería Eléctrica y Electrónica, Universidad Nacional de Ingeniería, Lima, Perú
Inteligencia Artificial II (CBS06), Examen Parcial 2026-2

Resumen

Los sistemas de detección de intrusiones (IDS) desplegados en redes IoT de borde enfrentan un dilema: centralizar el tráfico de los dispositivos expone datos sensibles y consume ancho de banda, mientras que entrenar un modelo aislado en cada dispositivo solo permite reconocer los ataques que ese dispositivo ya observó. Este estudio evalúa si el aprendizaje federado mejora la capacidad de detección de los IDS frente al entrenamiento aislado, sin compartir datos crudos. A partir de las capturas PCAP crudas de Edge-IIoTset se extrajeron 176 118 flujos bidireccionales con un extractor propio que excluye identificadores (IP, puertos y marcas de tiempo), y se simularon cinco clientes federados, cada uno con el tráfico etiquetado de un tipo de sensor y con distribuciones de clases no independientes ni idénticamente distribuidas (no-IID). Se compararon un perceptrón multicapa entrenado de forma local, centralizada y federada (FedAvg y FedProx) en cinco semillas, con la prueba de Wilcoxon. El aprendizaje federado elevó el F1 macro de 12,13 % a 30,41 % y la detección de ataques no vistos localmente de 0,03 % a 25,05 % ($p < 0,001$), y redujo en 53,7 % el volumen transmitido frente a centralizar los registros de flujo. FedProx ($\mu = 0,01$) alcanzó 52,57 %, mientras que FedAvg con datos IID igualó al modelo centralizado (82,91 % frente a 83,55 %). Con 100 rondas, FedProx llegó a 63,1 %, todavía a 20,5 pp del modelo centralizado. Se concluye que el aprendizaje federado mejora significativamente la detección respecto al entrenamiento aislado, pero la heterogeneidad entre dispositivos es el principal obstáculo para alcanzar el desempeño centralizado.

Palabras clave: aprendizaje federado, detección de intrusiones, Internet de las cosas, datos no-IID, FedProx, Edge-IIoTset

Ideas destacadas

- Un IDS entrenado solo con el tráfico de un dispositivo no detecta los ataques que ese dispositivo nunca observó (F1 = 0,03 %); el aprendizaje federado los eleva a 25,05 % sin compartir datos.
- Con datos IID, FedAvg queda a 0,64 pp del modelo centralizado; con heterogeneidad no-IID la brecha sube a 53,14 pp, y FedProx la reduce a 30,98 pp.
- El entrenamiento federado transmite 5,51 MB frente a 11,90 MB de registros de flujo y 255,8 MB de tráfico que exigiría centralizar los datos.

1. Introducción

El Internet de las cosas (IoT) y su variante industrial (IIoT) han desplazado el procesamiento hacia el borde de la red: sensores de bajo costo, controladores y pasarelas que publican datos mediante protocolos como MQTT o Modbus/TCP. Esta expansión amplía la superficie de ataque, porque los dispositivos tienen recursos limitados, se administran de forma heterogénea y son blanco frecuente de denegación de servicio, reconocimiento, inyección y malware (Ferrag et al., 2022; Khan et al., 2021). Los sistemas de detección de intrusiones (IDS)

basados en aprendizaje automático son una de las principales defensas en este entorno, pero su *capacidad de detección* depende de cómo y con qué datos se entrenan.

La problemática de la variable dependiente aparece en los dos esquemas de entrenamiento habituales. El esquema centralizado exige enviar el tráfico de todos los dispositivos a un servidor, lo que expone información sensible, consume ancho de banda y crea un punto único de falla (AbdulRahman et al., 2020; Vyas et al., 2024). El esquema aislado, en el que cada dispositivo entrena su propio modelo, evita ese envío, pero produce detectores que solo reconocen los ataques presentes en su tráfico local y fallan ante amenazas que nunca observaron (AbdulRahman et al., 2020). En ambos casos la capacidad de detección resulta deficiente para un despliegue real en el borde.

El aprendizaje federado (FL) propone una tercera vía: los dispositivos entrenan de forma colaborativa un modelo global y solo comparten sus parámetros, nunca los datos crudos (McMahan et al., 2017). Diversas revisiones lo señalan como un habilitador de IDS colaborativos que preservan la privacidad (Agrawal et al., 2022; Belenguer et al., 2025; Mármol Campos et al., 2022). Sin embargo, su desempeño se degrada cuando los datos de cada dispositivo no son independientes ni idénticamente distribuidos (no-IID), condición propia de las redes IoT reales, donde cada tipo de dispositivo genera un tráfico distinto y sufre ataques distintos (Li et al., 2022; Peng et al., 2025).

El vacío que aborda este estudio tiene dos componentes. Primero, gran parte de las evaluaciones parte de conjuntos de características ya preprocesados, como los CSV que acompañan a los propios datasets (Ferrag et al., 2022; Neto et al., 2023), lo que impide controlar la extracción de características y puede introducir atributos de identidad (direcciones o puertos) que inflan los resultados. Segundo, es poco frecuente cuantificar, para el mismo modelo y presupuesto de entrenamiento, cuánto mejora el FL la detección de ataques que un dispositivo nunca vio localmente, qué brecha conserva frente al modelo centralizado y cuánto reduce la comunicación. El aporte de este trabajo es un experimento reproducible que parte de capturas PCAP crudas, define una partición no-IID realista por tipo de dispositivo y mide esas tres dimensiones.

En consecuencia, el propósito del estudio es desarrollar un esquema de aprendizaje federado que mejore la capacidad de detección de los IDS en redes IoT de borde. Los objetivos específicos son: (a) analizar en qué medida el FL mejora el desempeño predictivo; (b) evaluar en qué medida mejora la generalización entre dispositivos; y (c) determinar en qué medida mejora la eficiencia del entrenamiento. La hipótesis general sostiene que el FL mejora significativamente la capacidad de detección frente al entrenamiento aislado. La motivación es práctica: un operador de ciudad inteligente o de planta industrial necesita que cada dispositivo se defienda de ataques que aún no ha sufrido, sin exportar su tráfico.

2. Revisión de la literatura

AbdulRahman et al. (2020) compararon tres esquemas para la detección de intrusiones en IoT: centralizado, en el dispositivo y federado. Concluyeron que el FL se aproxima al desempeño centralizado preservando la privacidad, mientras que el aprendizaje solo en el dispositivo queda limitado por la escasez y el sesgo de los datos locales. Esa comparación motiva el diseño de este estudio, que usa el esquema aislado como línea base y el centralizado como cota superior.

Ferrag et al. (2022) publicaron Edge-IIoTset, un testbed IoT/IIoT de siete capas con más de diez tipos de sensores y catorce ataques agrupados en cinco categorías, y evaluaron modelos de aprendizaje automático y profundo en modo centralizado y federado sobre características extraídas por los autores. Mármol Campos et al. (2022) revisaron el uso de FL en IDS para IoT

y evaluaron distintas funciones de agregación con particiones IID y no-IID, y advirtieron que la heterogeneidad entre clientes reduce el desempeño del modelo global. Popoola et al. (2022) aplicaron aprendizaje profundo federado a la detección de botnets de día cero en dispositivos IoT de borde y obtuvieron un desempeño cercano al centralizado con menor exposición de los datos.

Desde la perspectiva del algoritmo, Li et al. (2022) mostraron en un estudio experimental amplio que el desbalance de etiquetas, en el que cada participante posee solo algunas clases, es el escenario más difícil para FedAvg. FedProx (Li et al., 2020) añade un término proximal que limita la deriva de los modelos locales y fue propuesto precisamente para redes heterogéneas. Propuestas recientes para IDS no-IID recurren a destilación de conocimiento (Peng et al., 2025) o a modelos personalizados basados en grafos (Oladele et al., 2026). Pocas de estas evaluaciones parten del tráfico crudo y miden a la vez la detección de ataques no vistos localmente y el costo de comunicación, que es el vacío que aborda este trabajo.

3. Metodología

La investigación tiene enfoque cuantitativo, es de tipo aplicada y de nivel explicativo. Se adoptó un diseño experimental computacional con preprueba y posprueba: el entrenamiento aislado en cada dispositivo constituye la preprueba (línea base) y el entrenamiento federado, el tratamiento. Este diseño se eligió porque permite manipular la variable independiente (el esquema de entrenamiento y su configuración) manteniendo constantes el modelo, los datos y el presupuesto de cómputo, y medir el efecto con réplicas por semilla, a la manera de las comparaciones de AbdulRahman et al. (2020) y Mármol Campos et al. (2022).

3.1. Dataset real

Se utilizó Edge-IIoTset (Ferrag et al., 2022), en particular sus capturas de paquetes crudas: 24 archivos PCAP (2,1 GB), diez de tráfico normal, uno por tipo de sensor, y catorce de ataques. No se emplearon los CSV preprocesados que acompañan al dataset. El análisis de las capturas mostró que el equipo atacante de la maqueta es la dirección 192.168.0.170, que nunca aparece en el tráfico normal, y que la víctima principal es 192.168.0.128; las inundaciones ICMP y TCP SYN emplean cientos de miles de direcciones de origen falsificadas.

3.2. Extracción y etiquetado de flujos

Se implementó un extractor propio de flujos bidireccionales sobre la biblioteca dpkt. Cada flujo agrupa los paquetes de una misma 5-tupla (protocolo y dirección y puerto de ambos extremos) en ambos sentidos, y termina por inactividad (60 s), al cumplir una ventana de 120 s o al final de la captura. La ventana divide las conexiones MQTT y Modbus/TCP persistentes, que duran horas, en varias observaciones. Por flujo se calculan 31 características: protocolo, duración, paquetes y bytes por sentido, estadísticas de tamaño de paquete y de tiempo entre llegadas, contadores de banderas TCP, tasas y relación de bajada/subida. Las direcciones, puertos y marcas de tiempo se conservan solo como metadatos y no ingresan al modelo, para que este aprenda el comportamiento del tráfico y no la identidad de los equipos. Cada captura se truncó a un millón de paquetes.

Las capturas de ataque contienen también tráfico legítimo de fondo. Por ello, un flujo de una captura de ataque se etiquetó como ataque solo si alguno de sus extremos es una dirección que no aparece en ninguna captura normal; el resto se descartó. La regla etiquetó como ataque entre el 45 % (Ransomware) y el 99,8 % (DDoS HTTP) de los flujos de cada captura. La captura de MITM produjo solo dos flujos, porque el ataque es un envenenamiento ARP de capa

2 sin tráfico IP propio, y se excluyó (umbral mínimo de 100 flujos). Se eliminaron los vectores duplicados dentro de cada clase, para que filas idénticas no quedaran a la vez en entrenamiento y prueba, y cada clase y cada sensor se limitaron a 15 000 flujos. El dataset final contiene 176,118 flujos en 14 clases: tráfico normal y 13 ataques (Tabla 1).

Tabla 1

Composición del dataset de flujos utilizado en el experimento

Clase	Categoría	Flujos etiquetados	Flujos únicos	Flujos usados
Normal (5 sensores)	Normal	279 366	275 104	75 000
DDoS HTTP Flood	DDoS	12 339	12 173	12 173
DDoS ICMP Flood	DDoS	755 569	1 964	1 964
DDoS TCP SYN Flood	DDoS	512 429	948	948
DDoS UDP Flood	DDoS	926 410	20	50
SQL injection	Inyección	4 387	4 387	4 387
Uploading	Inyección	7 580	4 925	4 925
XSS	Inyección	1 158	1 158	1 158
MITM	MITM	2	0	excluida
Backdoor	Malware	921	836	836
Password	Malware	89 747	89 732	15 000
Ransomware	Malware	650	634	634
OS Fingerprinting	Reconocimiento	149	94	94
Port Scanning	Reconocimiento	9 987	208	208
Vulnerability scanner	Reconocimiento	2 629	2 621	2 621

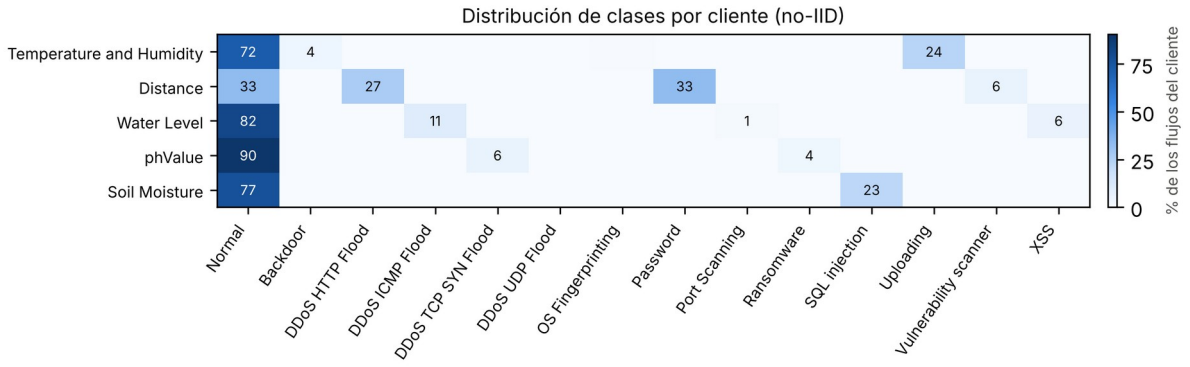
Nota. Normal corresponde a los cinco sensores usados como clientes (15 000 flujos cada uno). En DDoS UDP, con solo 20 vectores únicos, se conservaron flujos repetidos hasta 50 para permitir la partición estratificada. MITM se excluyó por tener solo 2 flujos IP.

3.3. Simulación de los dispositivos y partición de los datos

Se simularon K = 5 clientes, uno por tipo de sensor: temperatura y humedad, ultrasónico (distancia), nivel de agua, pH y humedad del suelo. Cada cliente representa la pasarela (gateway) o nodo de borde que concentra el tráfico de los sensores de ese tipo, y no el sensor en sí, que solo genera tráfico; el escenario corresponde, por tanto, a un FL entre pocos participantes con capacidad de cómputo (cross-silo). El 80 % de los flujos se usó para entrenamiento y el 20 % para prueba, con estratificación por clase y sensor. En la partición *no-IID*, cada cliente entrena con el tráfico normal de su sensor y con un subconjunto disjunto de dos o tres de los 13 ataques, de modo que cada ataque es observado por un solo dispositivo (Figura 1). En la partición *IID*, el mismo total se baraja y se reparte en partes iguales. La heterogeneidad se midió con la divergencia de Jensen-Shannon (JS, base 2) entre la distribución de clases de cada cliente y la global: 0,216 en promedio en la partición no-IID (rango 0,167–0,231) y 0,000 en la IID. El conjunto de prueba de cada cliente incluye el tráfico normal de su sensor y todos los ataques, porque en un despliegue real cualquier ataque puede alcanzar a cualquier dispositivo.

Figura 1

Distribución de clases de entrenamiento por cliente en la partición no-IID



Nota. Porcentaje de los flujos de entrenamiento de cada cliente que corresponde a cada clase. Cada ataque pertenece a un solo cliente.

El estudio adopta un enfoque supervisado y supone que cada cliente dispone de flujos etiquetados para su entrenamiento local. Las etiquetas no se requieren en tiempo real, porque el entrenamiento federado procede por rondas periódicas: en un despliegue podrían llegar con retraso desde un IDS basado en firmas, desde incidentes confirmados por analistas o desde pruebas de penetración. En este experimento, en cambio, provienen de la regla de etiquetado del testbed (sección 3.2), que no está disponible en una red en producción. Por ello, los resultados miden el beneficio del FL con supervisión completa y deben interpretarse como una cota superior de lo alcanzable cuando las etiquetas son escasas o tardías.

3.4. Esquemas comparados y métricas

Se compararon seis esquemas con el mismo modelo y el mismo presupuesto de entrenamiento: local (aislado; preprueba), FedAvg no-IID (tratamiento principal), FedAvg IID, FedProx con $\mu = 0{,}01$ y $\mu = 0{,}1$ en el escenario no-IID, y centralizado (cota superior). En cada cliente se midieron: el F1 macro sobre las clases presentes en su conjunto de prueba; la tasa de falsos positivos (FPR), es decir, la proporción de flujos normales clasificados como ataque; la brecha frente al modelo centralizado, $\Delta F1 = F1_{central} - F1_{esquema}$; y el F1 macro restringido a los ataques ausentes de los datos de entrenamiento del cliente en la partición no-IID ($F1_{nv}$). La eficiencia se midió con el volumen de comunicación acumulado y con el tiempo de entrenamiento local por ronda.

$$V = 2 \cdot K \cdot R \cdot |w| \cdot 4\ B$$

donde $|w|$ es el número de parámetros del modelo y 4 B el tamaño de un parámetro en coma flotante de 32 bits. Para el esquema centralizado se reporta el volumen de los registros de flujo de entrenamiento y el de los bytes de tráfico que habría que transmitir. El experimento se repitió con cinco semillas, que cambian la división de los datos, la inicialización y el orden de los lotes. Los resultados se presentan como media ± desviación estándar, y las diferencias se contrastaron con la prueba de rangos con signo de Wilcoxon, pareada por semilla y cliente ($n = 25$ pares, $\alpha = 0{,}05$). Los datos se recolectaron con una ficha de observación estructurada que se llena automáticamente desde los registros del experimento.

4. Desarrollo

4.1. Modelo de detección

El detector es un perceptrón multicapa (MLP) con arquitectura 31 → 64 → 32 → 14, activación ReLU en las capas ocultas y softmax en la salida (4,590 parámetros). Se eligió un modelo compacto porque es ejecutable en pasarelas y dispositivos de borde de recursos limitados y porque su tamaño determina directamente el costo de comunicación del FL. Se entrena con entropía cruzada y el optimizador Adam (tasa de aprendizaje 0,001, lote de 256). El modelo, FedAvg y FedProx se implementaron desde cero en NumPy, sin bibliotecas de aprendizaje profundo, para que cada operación del entrenamiento y la agregación sea explícita y verificable.

4.2. Preprocesamiento federado

Las características tienen colas pesadas, por lo que se transforman con $x' = \text{sign}(x) \cdot \ln(1 + |x|)$. La estandarización posterior no puede ajustarse sobre los datos de todos los clientes sin violar la premisa del FL. Por ello, cada cliente envía solo su número de muestras, la suma y la suma de cuadrados de cada característica, y el servidor calcula la media y la desviación estándar globales. El esquema aislado usa estadísticas locales y el centralizado, estadísticas de todo el conjunto.

4.3. Algoritmos de entrenamiento

Los modelos se organizan en tres niveles de colaboración. En el nivel aislado, cada cliente entrena su MLP durante $R \times E = 60$ épocas solo con sus datos. En el nivel federado, el entrenamiento procede por rondas, como describen McMahan et al. (2017):

1. El servidor difunde el modelo global w_t a los K clientes.
2. Cada cliente k entrena $E = 2$ épocas locales sobre sus datos partiendo de w_t y obtiene w_k^{t+1}.
3. El servidor agrega los modelos ponderando por el número de muestras n_k de cada cliente y repite durante $R = 30$ rondas:

$$w_{t+1} = \Sigma_k \, (n_k \,/\, n) \cdot w_k^{t+1}$$

FedProx (Li et al., 2020) modifica el paso 2: cada cliente minimiza su pérdida local más un término proximal que penaliza alejarse del modelo global,

$$\min_w \; F_k(w) + (\mu/2) \cdot \|w - w_t\|^2$$

con $\mu \in \{0{,}01; 0{,}1\}$. En el nivel centralizado, un único MLP se entrena 60 épocas con la unión de los datos de entrenamiento de todos los clientes. Así, los tres niveles comparten arquitectura, optimizador y número total de épocas, y solo difieren en qué datos ve cada modelo.

5. Resultados

La Tabla 2 resume el desempeño de los seis esquemas. El entrenamiento aislado obtuvo un F1 macro de 12,13 %: cada dispositivo reconoce el tráfico normal y sus dos o tres ataques, pero no detecta ninguno de los demás ($F1_{nv}$ = 0,03 %). El aprendizaje federado con datos no-IID elevó el F1 a 30,41 % y la detección de ataques no vistos a 25,05 %, y redujo la brecha frente al modelo centralizado de 71,42 a 53,14 pp. FedProx mejoró de forma marcada sobre FedAvg en el mismo escenario: con $\mu = 0{,}01$ alcanzó 52,57 % de F1 y 48,85 % en ataques no vistos. Con datos IID, FedAvg prácticamente igualó al modelo centralizado (82,91 % frente a 83,55 %), lo que confirma que la brecha del escenario no-IID se debe a la heterogeneidad entre dispositivos

y no al esquema federado en sí. La tasa de falsos positivos fue inferior a 0,05 % en todos los esquemas, porque el tráfico normal de los sensores es muy regular y fácil de separar.

Tabla 2

Capacidad de detección por esquema de entrenamiento (media ± desviación estándar en 5 semillas)

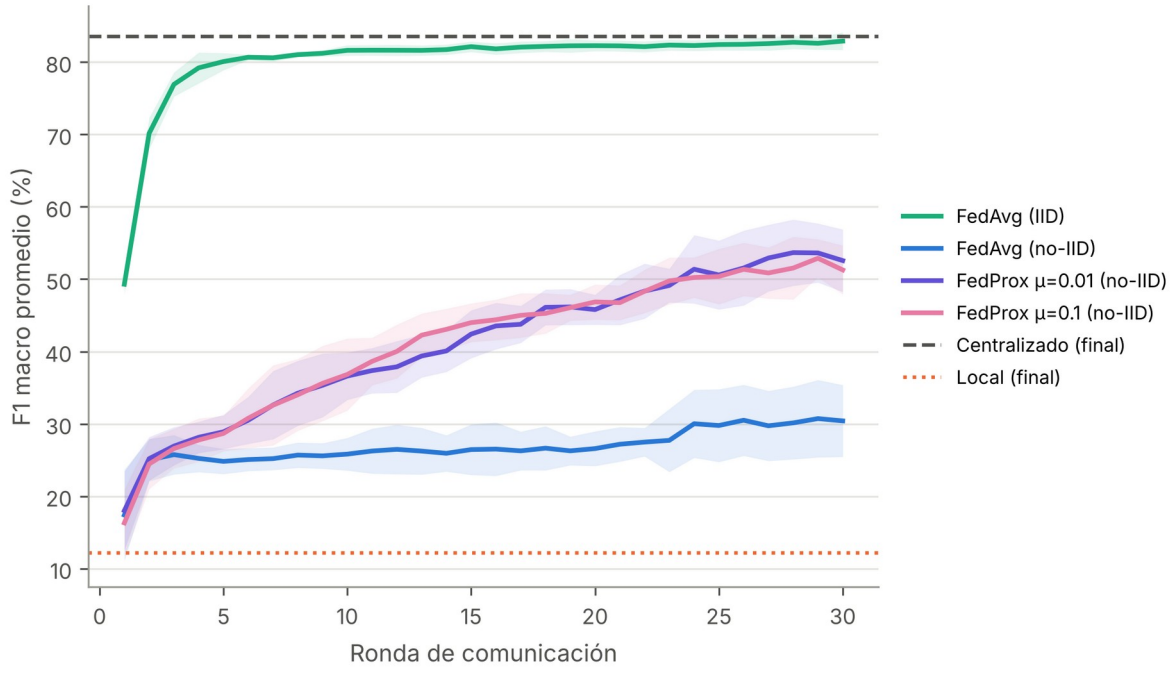
Esquema	F1 macro (%)	FPR (%)	ΔF1 (pp)	F1 no vistos (%)	Com. (MB)
Local (preprueba)	12,13 ± 0,39	0,01 ± 0,01	71,42 ± 0,73	0,03 ± 0,07	0,00
FedAvg no-IID (posprueba)	30,41 ± 4,96	0,04 ± 0,02	53,14 ± 4,89	25,05 ± 5,29	5,51
FedProx μ = 0,01 no-IID	52,57 ± 4,32	0,02 ± 0,01	30,98 ± 4,63	48,85 ± 4,67	5,51
FedProx μ = 0,1 no-IID	51,28 ± 3,38	0,03 ± 0,03	32,27 ± 3,81	47,45 ± 3,65	5,51
FedAvg IID	82,91 ± 1,21	0,03 ± 0,03	0,64 ± 0,84	81,64 ± 1,29	5,51
Centralizado	83,55 ± 0,51	0,02 ± 0,01	0,00 ± 0,00	82,33 ± 0,56	11,90

Nota. Promedio de los cinco clientes. ΔF1 = brecha frente al modelo centralizado. Com. = volumen de comunicación acumulado; para el esquema centralizado corresponde al envío de los registros de flujo (el tráfico crudo equivaldría a 255,8 MB). Local no transmite datos.

La Figura 2 muestra la evolución del F1 durante las rondas. FedAvg IID converge en menos de diez rondas al nivel centralizado. En el escenario no-IID, FedAvg se estanca cerca del 25 % durante las primeras veinte rondas, mientras que FedProx crece de forma sostenida. Ninguno de los dos alcanza la cota centralizada en 30 rondas.

Figura 2

Evolución del F1 macro promedio por ronda de comunicación



Nota. Media de cinco semillas; la banda sombreada indica ± una desviación estándar. Las líneas horizontales muestran el valor final de los esquemas centralizado y local.

La Tabla 3 presenta el contraste de hipótesis. Las mejoras del FL no-IID sobre el entrenamiento aislado en F1, en detección de ataques no vistos y en la brecha frente al centralizado fueron significativas ($p < 0,001$). La diferencia en la tasa de falsos positivos no fue

significativa (p = 0,076), dado que ambos esquemas se encuentran en un efecto techo (FPR < 0,05 %). FedProx superó significativamente a FedAvg en ambos coeficientes μ, y el paso de datos IID a no-IID redujo significativamente el F1.

Tabla 3

Prueba de rangos con signo de Wilcoxon pareada por semilla y cliente (n = 25)

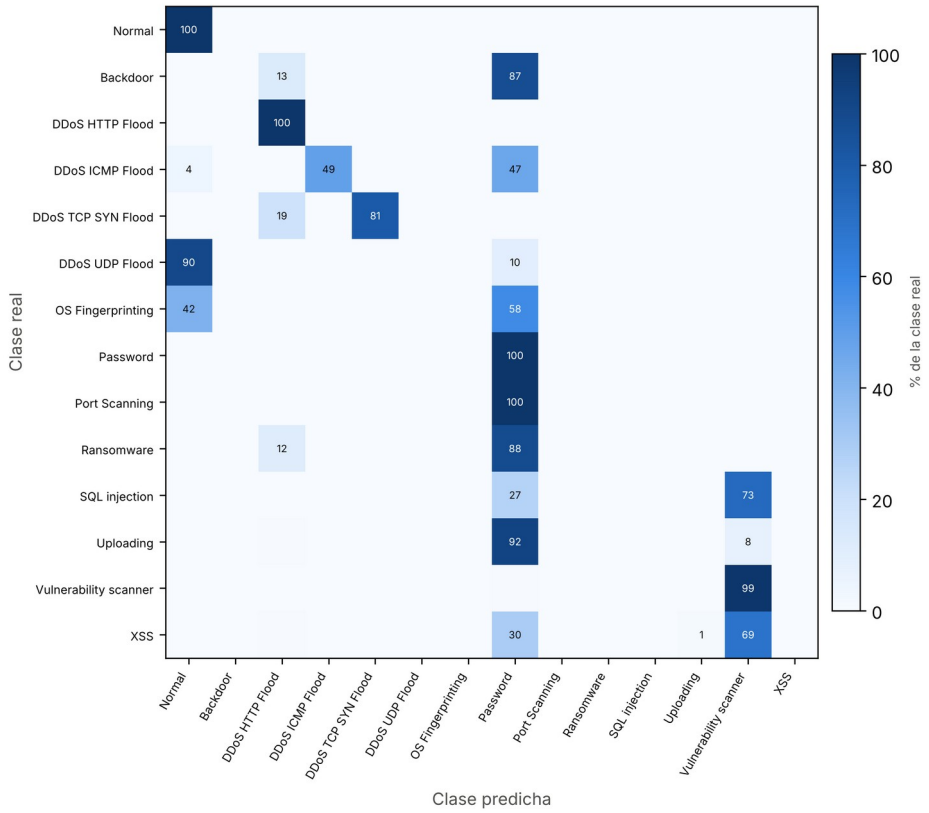
Comparación (A → B)	Métrica	Media A	Media B	Mediana Δ	p
Local → FedAvg no-IID	F1	12,13	30,41	20,00	< 0,001
Local → FedAvg no-IID	F1 nv	0,03	25,05	26,60	< 0,001
Local → FedAvg no-IID	FPR	0,01	0,04	0,00	0,076
Local → FedAvg no-IID	ΔF1	71,42	53,14	-20,00	< 0,001
FedAvg IID → FedAvg no-IID	F1	82,91	30,41	-53,85	< 0,001
FedAvg no-IID → FedProx 0,01	F1	30,41	52,57	23,28	< 0,001
FedAvg no-IID → FedProx 0,1	F1	30,41	51,28	21,32	< 0,001
FedAvg no-IID → FedProx 0,01	F1 nv	25,05	48,85	24,81	< 0,001
FedAvg no-IID → FedProx 0,1	F1 nv	25,05	47,45	22,93	< 0,001

Nota. Mediana Δ = mediana de la diferencia B − A. ΔF1: valores menores indican mejor desempeño. Los 25 pares no son plenamente independientes (los cinco clientes de una semilla comparten la partición), por lo que los valores p deben leerse como indicativos.

El análisis por clase (Figura 3) explica la brecha restante. El modelo global de FedAvg no-IID clasifica la mayoría de los ataques que no reconoce como *Password*, la clase más numerosa, que pertenece al cliente con más datos de entrenamiento (el sensor ultrasónico). Esto evidencia el sesgo de la agregación ponderada por número de muestras ante un desbalance extremo de etiquetas. Las inyecciones web (SQL, XSS, Uploading) y los ataques de baja frecuencia (Backdoor, Ransomware, OS Fingerprinting) son los más afectados, mientras que las inundaciones DDoS HTTP y TCP SYN se detectan casi por completo.

Figura 3

Matriz de confusión del modelo global FedAvg no-IID (semilla 0)



Nota. Porcentaje de cada clase real asignado a cada clase predicha, sobre la unión de los conjuntos de prueba de los cinco clientes.

Para la tercera dimensión de la variable independiente, la configuración del entrenamiento federado, se varió el número de épocas locales E ∈ {1, 2, 5} y se registró el desempeño hasta R = 100 rondas en el escenario no-IID, con tres semillas (Tabla 4 y Figura 4). Aumentar las rondas mejora ambos algoritmos: FedAvg pasa de 29,2 % en R = 30 a 38,5 % en R = 100 con E = 2, y FedProx, de 50,5 % a 57,4 %. El mejor resultado se obtuvo con FedProx, E = 5 y R = 100 (63,1 % de F1 y 60,2 % en ataques no vistos). El efecto de E fue pequeño e inconsistente frente a su variabilidad entre semillas. Incluso con 100 rondas, ninguna configuración no-IID superó el 63,1 %, a 20,5 pp del modelo centralizado (83,6 %). Esto indica que la brecha se debe principalmente a la heterogeneidad de los datos y no a la falta de entrenamiento.

Tabla 4

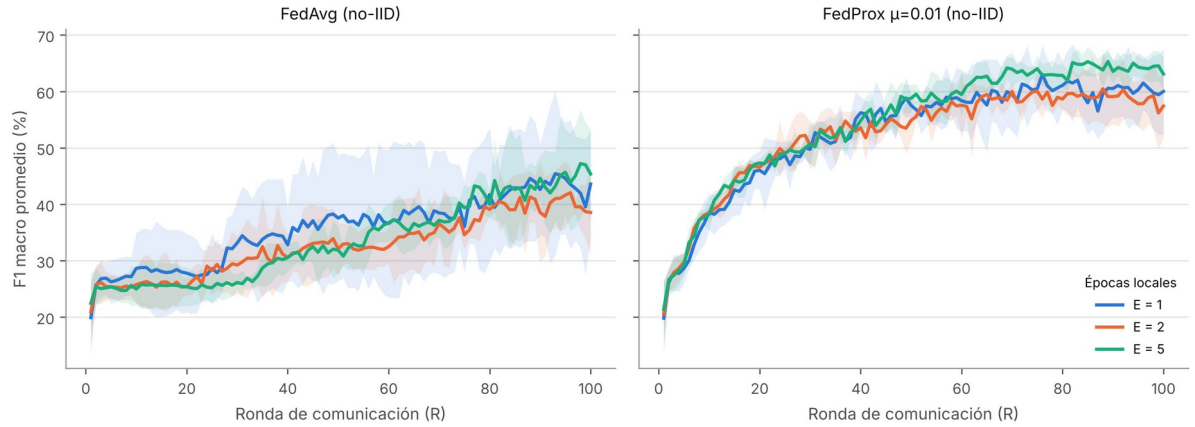
F1 macro (%) en el escenario no-IID según rondas (R) y épocas locales (E)

Esquema	E	R = 10	R = 30	R = 60	R = 100
FedAvg	1	28,7 ± 6,2	33,1 ± 7,5	36,6 ± 13,1	43,6 ± 9,4
FedAvg	2	25,7 ± 3,1	29,2 ± 5,1	32,5 ± 3,0	38,5 ± 7,4
FedAvg	5	25,0 ± 2,8	26,1 ± 1,4	36,7 ± 3,3	45,4 ± 7,9
FedProx μ = 0,01	1	38,6 ± 3,2	49,7 ± 2,6	58,4 ± 5,5	60,0 ± 7,6
FedProx μ = 0,01	2	38,5 ± 1,5	50,5 ± 4,2	57,6 ± 5,8	57,4 ± 5,8
FedProx μ = 0,01	5	38,2 ± 2,8	50,7 ± 3,5	59,5 ± 3,8	63,1 ± 2,9

Nota. Media ± desviación estándar en tres semillas. El valor en R = r equivale a fijar ese número de rondas.

Figura 4

Sensibilidad del F1 macro a las rondas de comunicación y a las épocas locales (no-IID)



Nota. Media de tres semillas; la banda sombreada indica ± una desviación estándar.

En cuanto a la eficiencia, el entrenamiento federado transmitió 5,51 MB en 30 rondas, frente a 11,90 MB que exigiría enviar los registros de flujo de entrenamiento al servidor (−53,7 %) y 255,8 MB si se enviara el tráfico de esos flujos (−97,8 %). El tiempo de entrenamiento local por ronda fue de 0,066 s en el esquema federado, frente a 0,067 s en el aislado. El FL no añade, por tanto, carga de cómputo apreciable al nodo cliente.

6. Discusión

Los resultados respaldan la conclusión de AbdulRahman et al. (2020): el entrenamiento solo en el dispositivo es insuficiente y el FL se aproxima al centralizado cuando los datos son homogéneos, como confirma el FedAvg IID, a 0,64 pp de la cota. La degradación observada al pasar a la partición no-IID (−52,5 pp) es coherente con Li et al. (2022), quienes identificaron el desbalance de etiquetas, en el que cada participante posee pocas clases, como el escenario más adverso para FedAvg, y con las advertencias de Mármol Campos et al. (2022) sobre la heterogeneidad en IDS federados. La mejora de FedProx (+22,2 pp de F1) concuerda con su motivación original: limitar la deriva de los modelos locales en redes heterogéneas (Li et al., 2020).

El hallazgo central para la seguridad es la detección de ataques no vistos localmente. Un dispositivo aislado no detecta ninguno de los ataques que no observó (0,03 %), lo que en la práctica significa que un sensor de pH no reconocería una inyección SQL dirigida a él si solo el sensor de humedad la ha sufrido. El FL transfiere ese conocimiento sin mover datos (25,05 % con FedAvg y 48,85 % con FedProx), en línea con los resultados de Popoola et al. (2022) para botnets de día cero. No obstante, la matriz de confusión muestra que la agregación ponderada favorece las clases del cliente con más datos. Ello sugiere que, en IDS federados con desbalance de etiquetas, la ponderación por número de muestras no es neutral y conviene explorar agregaciones conscientes de las clases.

Respecto a la eficiencia, el FL redujo el volumen transmitido en 53,7 % frente a centralizar los registros de flujo, y en 97,8 % frente a centralizar el tráfico, porque lo que viaja es un modelo de 4,590 parámetros y no los datos. Esta ventaja crece con el volumen de tráfico y se reduce si aumentan las rondas o el tamaño del modelo, lo que refuerza la elección de modelos compactos en el borde (Bhavsar et al., 2024; Khan et al., 2021). Sin embargo, el costo de comunicación crece linealmente con las rondas: con R = 100 el entrenamiento federado transmitiría 18,4 MB, más que los registros de flujo centralizados (11,9 MB), aunque muy por

debajo del tráfico crudo (255,8 MB). La mejora de desempeño que aportan más rondas tiene, por tanto, un costo de comunicación que el despliegue debe ponderar.

La validez práctica de estos resultados depende de cómo obtiene cada cliente sus etiquetas. Una arquitectura realista es jerárquica: los sensores generan el tráfico, la pasarela de cada sitio extrae los flujos, ejecuta el detector y participa en el FL, y el servidor agrega los modelos. En la pasarela, las etiquetas pueden llegar con retraso desde reglas de firmas, incidentes confirmados o capturas controladas, aunque las derivadas de firmas trasladan al modelo los puntos ciegos de esas reglas. Para el tráfico sin etiquetar, un detector de anomalías federado entrenado solo con tráfico normal, como DÏoT (Nguyen et al., 2019), no necesita etiquetas de ataque y puede reconocer amenazas nuevas, pero no identifica su tipo y suele producir más falsos positivos. Combinar ambos en cascada, de modo que el detector de anomalías filtre los flujos sospechosos y solo estos se etiqueten para entrenar el clasificador federado multiclase, reduce el esfuerzo de etiquetado y conserva la identificación del tipo de ataque, que orienta la respuesta. El aprendizaje federado semisupervisado, con pocas etiquetas en el servidor o en los clientes (Jeong et al., 2021), es otra vía; sin embargo, con desbalance de etiquetas, el pseudoetiquetado podría reforzar el sesgo hacia las clases dominantes observado en la Figura 3.

Este estudio tiene limitaciones. Los datos provienen de un único testbed y de un solo atacante, por lo que la regla de etiquetado por dirección no vista podría requerir ajustes en otras redes. La captura de MITM no aporta flujos IP observables. Las capturas se truncaron a un millón de paquetes y las clases DDoS presentan muy pocos vectores únicos. El FL se simuló en una sola máquina, con cinco clientes y sin pérdidas de red. Además, se supuso supervisión completa en cada cliente; con etiquetas escasas o tardías, el efecto de la heterogeneidad probablemente sería mayor, por lo que los valores reportados constituyen una cota superior. Como líneas futuras se proponen: agregaciones ponderadas por clase o con destilación de conocimiento (Peng et al., 2025); FL personalizado o por agrupamiento de clientes (Oladele et al., 2026); evaluar el esquema con fracciones reducidas de flujos etiquetados y combinarlo en cascada con detectores de anomalías federados no supervisados (Nguyen et al., 2019; Oladele et al., 2026); incorporar agregación segura o privacidad diferencial (Vyas et al., 2024); y desplegar el esquema en dispositivos de borde reales para medir latencia y consumo energético.

7. Conclusiones

La hipótesis general se valida parcialmente: el aprendizaje federado mejora significativamente la capacidad de detección de los IDS frente al entrenamiento aislado (F1 de 12,13 % a 30,41 % con FedAvg y a 52,57 % con FedProx; $p < 0{,}001$), pero con datos no-IID permanece lejos del modelo centralizado. La primera hipótesis específica se cumple para el F1 macro y no para la tasa de falsos positivos, que ya era casi nula en ambos esquemas. La segunda se cumple: el FL eleva la detección de ataques no vistos localmente de 0,03 % a 25,05 % y reduce la brecha frente al centralizado en 18,3 pp. La tercera también se cumple: el volumen transmitido es 53,7 % menor que el de centralizar los registros de flujo, sin aumentar el tiempo de entrenamiento local.

La novedad del trabajo radica en evaluar el FL desde capturas PCAP crudas, con un extractor que excluye atributos de identidad y una partición no-IID por tipo de dispositivo, y en medir de forma explícita la detección de ataques que cada dispositivo nunca observó. El principal aporte es cuantificar que la heterogeneidad entre dispositivos, y no el esquema federado en sí, explica la brecha frente al modelo centralizado, y que FedProx recupera una parte importante de ella. En la práctica, para la motivación planteada en la introducción, un operador puede desplegar detectores federados que protegen a cada dispositivo frente a ataques

que solo otros han sufrido, sin exportar su tráfico, siempre que las pasarelas dispongan de tráfico etiquetado, aunque sea con retraso, y se usen estrategias robustas a la heterogeneidad como FedProx.

Dataset y código fuente

Código fuente, notebooks y resultados: https://github.com/Pipo-z-z/fl-ids-edgeiiotset. Dataset: Edge-IIoTset (Ferrag et al., 2022), disponible en IEEE DataPort (https://ieee-dataport.org/documents/edge-iiotset-new-comprehensive-realistic-cyber-security-dataset-iot-and-iiot-applications) y en Kaggle; se usaron los 24 archivos PCAP crudos. El repositorio incluye la tabla de flujos etiquetados generada en este estudio.

Referencias

AbdulRahman, S., Tout, H., Talhi, C., & Mourad, A. (2020). Internet of Things intrusion detection: Centralized, on-device, or federated learning? *IEEE Network, 34*(6), 310–317. https://doi.org/10.1109/MNET.011.2000286

Agrawal, S., Sarkar, S., Aouedi, O., Yenduri, G., Piamrat, K., Alazab, M., Bhattacharya, S., Maddikunta, P. K. R., & Gadekallu, T. R. (2022). Federated learning for intrusion detection system: Concepts, challenges and future directions. *Computer Communications, 195*, 346–361. https://doi.org/10.1016/j.comcom.2022.09.012

Belenguer, A., Pascual, J. A., & Navaridas, J. (2025). A review of federated learning applications in intrusion detection systems. *Computer Networks, 258*, Artículo 111023. https://doi.org/10.1016/j.comnet.2024.111023

Bhavsar, M., Bekele, Y. B., Roy, K., Kelly, J. C., & Limbrick, D. B. (2024). FL-IDS: Federated learning-based intrusion detection system using edge devices for transportation IoT. *IEEE Access, 12*, 52215–52226. https://doi.org/10.1109/ACCESS.2024.3386631

Ferrag, M. A., Friha, O., Hamouda, D., Maglaras, L., & Janicke, H. (2022). Edge-IIoTset: A new comprehensive realistic cyber security dataset of IoT and IIoT applications for centralized and federated learning. *IEEE Access, 10*, 40281–40306. https://doi.org/10.1109/ACCESS.2022.3165809

Jeong, W., Yoon, J., Yang, E., & Hwang, S. J. (2021). Federated semi-supervised learning with inter-client consistency & disjoint learning. En *International Conference on Learning Representations (ICLR 2021)*. OpenReview. https://openreview.net/forum?id=ce6CFXBh30h

Khan, L. U., Saad, W., Han, Z., Hossain, E., & Hong, C. S. (2021). Federated learning for Internet of Things: Recent advances, taxonomy, and open challenges. *IEEE Communications Surveys & Tutorials, 23*(3), 1759–1799. https://doi.org/10.1109/COMST.2021.3090430

Li, Q., Diao, Y., Chen, Q., & He, B. (2022). Federated learning on non-IID data silos: An experimental study. En *2022 IEEE 38th International Conference on Data Engineering (ICDE)* (pp. 965–978). IEEE. https://doi.org/10.1109/ICDE53745.2022.00077

Li, T., Sahu, A. K., Zaheer, M., Sanjabi, M., Talwalkar, A., & Smith, V. (2020). Federated optimization in heterogeneous networks. *Proceedings of Machine Learning and Systems, 2*, 429–450.

Mármol Campos, E., Fernández Saura, P., González-Vidal, A., Hernández-Ramos, J. L., Bernal Bernabé, J., Baldini, G., & Skarmeta, A. (2022). Evaluating federated learning

for intrusion detection in Internet of Things: Review and challenges. *Computer Networks, 203*, Artículo 108661. https://doi.org/10.1016/j.comnet.2021.108661

McMahan, B., Moore, E., Ramage, D., Hampson, S., & Agüera y Arcas, B. (2017). Communication-efficient learning of deep networks from decentralized data. En *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics* (Vol. 54, pp. 1273–1282). PMLR.

Neto, E. C. P., Dadkhah, S., Ferreira, R., Zohourian, A., Lu, R., & Ghorbani, A. A. (2023). CICIoT2023: A real-time dataset and benchmark for large-scale attacks in IoT environment. *Sensors, 23*(13), Artículo 5941. https://doi.org/10.3390/s23135941

Nguyen, T. D., Marchal, S., Miettinen, M., Fereidooni, H., Asokan, N., & Sadeghi, A.-R. (2019). DÏoT: A federated self-learning anomaly detection system for IoT. En *2019 IEEE 39th International Conference on Distributed Computing Systems (ICDCS)* (pp. 756–767). IEEE. https://doi.org/10.1109/ICDCS.2019.00080

Oladele, D. A., Ige, A. O., Agbo-Ajala, O., Ekundayo, O., Thottempudi, S. G., Sibiya, M., & Mnkandla, E. (2026). G-PFL-ID: Graph-driven personalized federated learning for unsupervised intrusion detection in non-IID IoT systems. *IoT, 7*(1), Artículo 13. https://doi.org/10.3390/iot7010013

Peng, H., Wu, C., & Xiao, Y. (2025). FD-IDS: Federated learning with knowledge distillation for intrusion detection in non-IID IoT environments. *Sensors, 25*(14), Artículo 4309. https://doi.org/10.3390/s25144309

Popoola, S. I., Ande, R., Adebisi, B., Gui, G., Hammoudeh, M., & Jogunola, O. (2022). Federated deep learning for zero-day botnet attack detection in IoT-edge devices. *IEEE Internet of Things Journal, 9*(5), 3930–3944. https://doi.org/10.1109/JIOT.2021.3100755

Vyas, A., Lin, P.-C., Hwang, R.-H., & Tripathi, M. (2024). Privacy-preserving federated learning for intrusion detection in IoT environments: A survey. *IEEE Access, 12*, 127018–127050. https://doi.org/10.1109/ACCESS.2024.3454211