Aprendizaje Federado:
Sistematización del Tema de Investigación

Línea de Investigación:

Aprendizaje federado aplicado a la detección de intrusiones

Diagnóstico Preliminar:

El problema central reside en la deficiente capacidad de detección de los sistemas de detección de intrusiones (IDS) desplegados en redes IoT de borde, impulsada por la dependencia de esquemas de entrenamiento centralizados o aislados, que resultan inadecuados para entornos distribuidos y heterogéneos. Por un lado, el enfoque centralizado exige transferir el tráfico de miles de dispositivos hacia un servidor, lo que expone información sensible, consume ancho de banda y crea un punto único de falla (AbdulRahman et al., 2020; Vyas et al., 2024). Por otro, el entrenamiento local en cada dispositivo produce modelos que solo reconocen los ataques presentes en su propio tráfico y fallan ante amenazas que nunca observaron (AbdulRahman et al., 2020). Esta vulnerabilidad sistémica tiene un doble impacto: primero, deja a las infraestructuras IoT e IIoT expuestas a ataques de denegación de servicio, reconocimiento, intermediario (MITM), inyección y malware, que se propagan con rapidez entre dispositivos de bajo costo y escasos recursos (Ferrag et al., 2022); y segundo, aunque el aprendizaje federado surge como alternativa para entrenar un modelo común sin compartir datos crudos, su desempeño se degrada cuando el tráfico de cada dispositivo sigue distribuciones no independientes ni idénticamente distribuidas (no-IID), condición propia de las redes IoT reales, donde cada tipo de dispositivo genera un tráfico distinto (Li et al., 2022; Peng et al., 2025).

Tema General:

Redes IoT de borde, 2026

Temas Particulares:

1. Sistemas de detección de intrusiones en redes IoT de borde, 2026
2. Seguridad de la información en redes IoT de borde, 2026
3. Privacidad de los datos de tráfico en redes IoT de borde, 2026

Temas Específicos:

1. Exposición de los datos de tráfico en los sistemas de detección de intrusiones centralizados en redes IoT de borde, 2026
2. Alto costo de comunicación en el entrenamiento de los sistemas de detección de intrusiones en redes IoT de borde, 2026
3. Deficiente capacidad de detección de los sistemas de detección de intrusiones en redes IoT de borde, 2026.

Problema de Estudio:

Deficiente capacidad de detección de los sistemas de detección de intrusiones en redes IoT de borde, 2026.

Título Preliminar:

Capacidad de detección de los sistemas de detección de intrusiones en redes IoT de borde, 2026.

- **Variable dependiente:** Capacidad de detección
- **Objeto de estudio:** Sistemas de detección de intrusiones (IDS)
- **Alcance espacial:** Redes IoT de borde
- **Alcance temporal:** 2026

Antecedentes Bibliográficos:

AbdulRahman, S., Tout, H., Talhi, C., & Mourad, A. (2020). Internet of Things intrusion detection: Centralized, on-device, or federated learning? *IEEE Network*, *34*(6), 310–317. https://doi.org/10.1109/MNET.011.2000286

Agrawal, S., Sarkar, S., Aouedi, O., Yenduri, G., Piamrat, K., Alazab, M., Bhattacharya, S., Maddikunta, P. K. R., & Gadekallu, T. R. (2022). Federated learning for intrusion detection system: Concepts, challenges and future directions. *Computer Communications*, *195*, 346–361. https://doi.org/10.1016/j.comcom.2022.09.012

Alayed, W. M., Tahir, H. A., & Hassan, W. U. (2026). Application-oriented evaluation of federated learning for IoT intrusion detection under non-IID conditions in wireless sensor networks. *Applied Sciences*, *16*(10), 5092. https://doi.org/10.3390/app16105092

Alazab, A., Khraisat, A., Singh, S., & Jan, T. (2023). Enhancing privacy-preserving intrusion detection through federated learning. *Electronics*, *12*(16), 3382. https://doi.org/10.3390/electronics12163382

Albanbay, N., Tursynbek, Y., Graffi, K., Uskenbayeva, R., Kalpeyeva, Z., Abilkaiyr, Z., & Ayapov, Y. (2025). Federated learning-based intrusion detection in IoT networks: Performance evaluation and data scaling study. *Journal of Sensor and Actuator Networks*, *14*(4), 78. https://doi.org/10.3390/jsan14040078

Anwar, R. W., Abrar, M., Salam, A., & Ullah, F. (2025). Federated learning with LSTM for intrusion detection in IoT-based wireless sensor networks: A multi-dataset analysis. *PeerJ Computer Science*, *11*, e2751. https://doi.org/10.7717/peerj-cs.2751

Belenguer, A., Pascual, J. A., & Navaridas, J. (2025). A review of federated learning applications in intrusion detection systems. *Computer Networks*, *258*, 111023. https://doi.org/10.1016/j.comnet.2024.111023

Bhavsar, M., Bekele, Y. B., Roy, K., Kelly, J. C., & Limbrick, D. B. (2024). FL-IDS: Federated learning-based intrusion detection system using edge devices for transportation IoT. *IEEE Access*, *12*, 52215–52226. https://doi.org/10.1109/ACCESS.2024.3386631

Ferrag, M. A., Friha, O., Hamouda, D., Maglaras, L., & Janicke, H. (2022). Edge-IIoTset: A new comprehensive realistic cyber security dataset of IoT and IIoT applications for centralized and federated learning. *IEEE Access*, *10*, 40281–40306. https://doi.org/10.1109/ACCESS.2022.3165809

Ferrag, M. A., Friha, O., Maglaras, L., Janicke, H., & Shu, L. (2021). Federated deep learning for cyber security in the Internet of Things: Concepts, applications, and experimental analysis. *IEEE Access*, *9*, 138509–138542. https://doi.org/10.1109/ACCESS.2021.3118642

Karunamurthy, A., Vijayan, K., Kshirsagar, P. R., & Tan, K. T. (2025). An optimal federated learning-based intrusion detection for IoT environment. *Scientific Reports*, *15*, 8696. https://doi.org/10.1038/s41598-025-93501-8

Khan, L. U., Saad, W., Han, Z., Hossain, E., & Hong, C. S. (2021). Federated learning for Internet of Things: Recent advances, taxonomy, and open challenges. *IEEE Communications Surveys & Tutorials*, *23*(3), 1759–1799. https://doi.org/10.1109/COMST.2021.3090430

Li, Q., Diao, Y., Chen, Q., & He, B. (2022). Federated learning on non-IID data silos: An experimental study. En *2022 IEEE 38th International Conference on Data Engineering (ICDE)* (pp. 965–978). IEEE. https://doi.org/10.1109/ICDE53745.2022.00077

Li, T., Sahu, A. K., Zaheer, M., Sanjabi, M., Talwalkar, A., & Smith, V. (2020). Federated optimization in heterogeneous networks. *Proceedings of Machine Learning and Systems*, *2*, 429–450.

Mármol Campos, E., Fernández Saura, P., González-Vidal, A., Hernández-Ramos, J. L., Bernal Bernabé, J., Baldini, G., & Skarmeta, A. (2022). Evaluating federated learning for intrusion detection in Internet of Things: Review and challenges. *Computer Networks*, *203*, 108661. https://doi.org/10.1016/j.comnet.2021.108661

McMahan, B., Moore, E., Ramage, D., Hampson, S., & Agüera y Arcas, B. (2017). Communication-efficient learning of deep networks from decentralized data. En *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics* (Vol. 54, pp. 1273–1282). PMLR.

Mothukuri, V., Khare, P., Parizi, R. M., Pouriyeh, S., Dehghantanha, A., & Srivastava, G. (2022). Federated-learning-based anomaly detection for IoT security attacks. *IEEE Internet of Things Journal*, *9*(4), 2545–2554. https://doi.org/10.1109/JIOT.2021.3077803

Neto, E. C. P., Dadkhah, S., Ferreira, R., Zohourian, A., Lu, R., & Ghorbani, A. A. (2023). CICIoT2023: A real-time dataset and benchmark for large-scale attacks in IoT environment. *Sensors*, *23*(13), 5941. https://doi.org/10.3390/s23135941

Oladele, D. A., Ige, A. O., Agbo-Ajala, O., Ekundayo, O., Thottempudi, S. G., Sibiya, M., & Mnkandla, E. (2026). G-PFL-ID: Graph-driven personalized federated learning for unsupervised intrusion detection in non-IID IoT systems. *IoT*, *7*(1), 13. https://doi.org/10.3390/iot7010013

Peng, H., Wu, C., & Xiao, Y. (2025). FD-IDS: Federated learning with knowledge distillation for intrusion detection in non-IID IoT environments. *Sensors*, *25*(14), 4309. https://doi.org/10.3390/s25144309

Popoola, S. I., Ande, R., Adebisi, B., Gui, G., Hammoudeh, M., & Jogunola, O. (2022). Federated deep learning for zero-day botnet attack detection in IoT-edge devices. *IEEE Internet of Things Journal*, *9*(5), 3930–3944. https://doi.org/10.1109/JIOT.2021.3100755

Rashid, M. M., Khan, S. U., Eusufzai, F., Redwan, M. A., Sabuj, S. R., & Elsharief, M. (2023). A federated learning-based approach for improving intrusion detection in industrial Internet of Things networks. *Network*, *3*(1), 158–179. https://doi.org/10.3390/network3010008

Vyas, A., Lin, P.-C., Hwang, R.-H., & Tripathi, M. (2024). Privacy-preserving federated learning for intrusion detection in IoT environments: A survey. *IEEE Access*, *12*, 127018–127050. https://doi.org/10.1109/ACCESS.2024.3454211

Título Tentativo:

Aprendizaje federado para mejorar la capacidad de detección de los sistemas de detección de intrusiones en redes IoT de borde, 2026.

- **Variable independiente:** Aprendizaje federado
- **Variable dependiente:** Capacidad de detección
- **Objeto de estudio:** Sistemas de detección de intrusiones (IDS)
- **Alcance espacial:** Redes IoT de borde
- **Alcance temporal:** 2026

MATRIZ DE OPERACIONALIZACIÓN DE VARIABLES

VARIABLE	DEFINICIÓN CONCEPTUAL	DEFINICIÓN OPERACIONAL	OPERACIONALIZACIÓN			ESCALA DE MEDICIÓN
			DIMENSIONES	INDICADORES	ÍNDICES	
VARIABLE INDEPENDIENTE (VI): Aprendizaje federado	El aprendizaje federado es un paradigma de aprendizaje automático distribuido en el que múltiples clientes entrenan de forma colaborativa un modelo global, coordinados por un servidor que agrega sus parámetros, sin que los datos crudos abandonen el dispositivo que los genera (McMahan et al., 2017; Khan et al., 2021). En la seguridad IoT permite construir IDS colaborativos que preservan la privacidad del tráfico local de cada dispositivo (Agrawal et al., 2022; Mármol Campos et al., 2022).	1 Estrategia de agregación: regla con la que el servidor combina los modelos locales, determinada por el algoritmo empleado (FedAvg o FedProx) y la intensidad del término proximal μ (McMahan et al., 2017; Li et al., 2020). 2 Heterogeneidad de los datos: grado en que difieren las distribuciones de clases entre los clientes, medido mediante la divergencia de Jensen-Shannon respecto a la distribución global y el número de clientes participantes (Li et al., 2022; Peng et al., 2025). 3 Configuración del entrenamiento federado: parámetros del proceso iterativo, medidos por el número de rondas de comunicación y de épocas locales por ronda (McMahan et al., 2017; Albanbay et al., 2025).	1 Estrategia de agregación	**Algoritmo de agregación:** regla de combinación de pesos aplicada por el servidor en cada ronda. $FedAvg:\ w(t+1) = \Sigma k\ (nk / n) \cdot wk(t+1)$	• FedAvg: promedio ponderado por el número de muestras de cada cliente. • FedProx: promedio con término proximal en la función de pérdida local.	Nominal
				Coeficiente proximal (μ): intensidad de la penalización que limita la deriva del modelo local respecto al modelo global. $min\ Fk(w) + (\mu/2)\cdot\|w - w(t)\|^2$	• Nulo: μ = 0 (equivale a FedAvg). • Bajo: 0 < μ ≤ 0.01. • Alto: μ ≥ 0.1.	Razón
			2 Heterogeneidad de los datos	**Grado de no-IID (JS):** divergencia de Jensen-Shannon promedio entre la distribución de clases de cada cliente y la distribución global. $JS = (1/K) \cdot \Sigma k\ JS(Pk \| Pglobal)$	• IID: $J\bar{S}$ < 0.05 (partición aleatoria). • Moderado: 0.05 – 0.30. • Alto: $J\bar{S}$ > 0.30 (partición por tipo de dispositivo).	Razón
				Número de clientes (K): cantidad de dispositivos IoT que participan en el entrenamiento federado. $K = N.º\ de\ clientes\ activos\ por\ ronda$	• Bajo: K ≤ 5. • Medio: 6 – 10. • Alto: K > 10.	Razón
			3 Configuración del entrenamiento federado	**Rondas de comunicación (R):** ciclos completos de difusión del modelo global, entrenamiento local y agregación. $R = N.º\ de\ rondas\ ejecutadas$	• Bajo: R ≤ 10. • Medio: 11 – 30. • Alto: R > 30.	Razón
				Épocas locales por ronda (E): pasadas completas sobre los datos locales antes de enviar el modelo al servidor. $E = N.º\ de\ épocas\ por\ ronda$	• Bajo: E = 1. • Medio: 2 – 5. • Alto: E > 5.	Razón
VARIABLE DEPENDIENTE (VD): Capacidad de detección	La capacidad de detección de un IDS es su aptitud para identificar correctamente el tráfico malicioso y distinguir sus categorías de ataque frente al tráfico benigno, con un mínimo de falsas alarmas, de forma consistente entre dispositivos con tráfico heterogéneo y dentro de las restricciones de recursos del borde de la red (Ferrag et al., 2022; Belenguer et al., 2025). En	1 Desempeño predictivo: exactitud con que el modelo clasifica los flujos de tráfico de prueba, medida mediante el F1-score macro y la tasa de falsos positivos (Ferrag et al., 2022; Karunamurthy et al., 2025). 2 Generalización entre dispositivos: consistencia del desempeño en clientes con tráfico heterogéneo, medida por la brecha de F1 frente al modelo centralizado y el F1 sobre	1 Desempeño predictivo	**F1-score macro (%):** media armónica de precisión y exhaustividad, promediada entre todas las clases (normal y tipos de ataque). $F1 = (1/C) \cdot \Sigma c\ [2\cdot Pc\cdot Rc / (Pc + Rc)] \times 100$	• Bajo (Insuficiente): < 85%. • Medio (Aceptable): 85% – 95%. • Alto (Óptimo): > 95%.	Razón
				Tasa de falsos positivos (%): proporción de flujos benignos clasificados erróneamente como ataque. $FPR = FP / (FP + TN) \times 100$	• Deficiente: > 5%. • Aceptable: 1% – 5%. • Óptimo: < 1%.	Razón

VARIABLE	DEFINICIÓN CONCEPTUAL	DEFINICIÓN OPERACIONAL	OPERACIONALIZACIÓN			ESCALA DE MEDICIÓN
			DIMENSIONES	INDICADORES	ÍNDICES	
	las redes IoT de borde busca mitigar la exposición de los dispositivos a ataques que eluden a los modelos entrenados con información parcial (AbdulRahman et al., 2020; Vyas et al., 2024).	ataques ausentes en los datos locales del cliente (AbdulRahman et al., 2020; Popoola et al., 2022). 3 Eficiencia del entrenamiento: recursos consumidos para obtener el modelo, medidos por el volumen de datos transmitidos y el tiempo de entrenamiento local (Khan et al., 2021; Bhavsar et al., 2024).	2 Generalización entre dispositivos	**Brecha frente al modelo centralizado (pp):** diferencia de F1 macro entre el modelo centralizado (cota superior) y el modelo evaluado. $\Delta F1 = F1central - F1evaluado$	• Deficiente: > 10 pp. • Aceptable: 3 – 10 pp. • Óptimo: < 3 pp.	Razón
				Detección de ataques no vistos localmente (%): F1 macro calculado solo sobre las clases de ataque ausentes en los datos de entrenamiento del cliente k. $F1nv,k = F1\ macro\ (clases \notin Dk) \times 100$	• Bajo: < 50%. • Medio: 50% – 80%. • Alto (Óptimo): > 80%.	Razón
			3 Eficiencia del entrenamiento	**Volumen de comunicación acumulado (MB):** datos transmitidos entre clientes y servidor hasta obtener el modelo final. $V = 2 \cdot K \cdot R \cdot \|w\| \cdot 4\ B\ /\ 10^6$	• Óptimo: < 10 MB. • Aceptable: 10 – 100 MB. • Deficiente: > 100 MB.	Razón
				Tiempo de entrenamiento local por ronda (s): tiempo promedio que cada cliente dedica a entrenar en una ronda. $T = (1/K) \cdot \Sigma k\ tk$	• Óptimo: < 5 s. • Aceptable: 5 – 30 s. • Deficiente: > 30 s.	Razón

MATRIZ DE CONSISTENCIA

Título: Aprendizaje federado para mejorar la capacidad de detección de los sistemas de detección de intrusiones en redes IoT de borde, 2026.

LÍNEA DE INVESTIGACIÓN	PROBLEMA DE ESTUDIO	PROBLEMAS	HIPÓTESIS	OBJETIVOS	VARIABLES Y DIMENSIONES	DISEÑO METODOLÓGICO
Aprendizaje federado aplicado a la detección de intrusiones **OBJETO DE ESTUDIO** Sistemas de detección de intrusiones (IDS)	Deficiente capacidad de detección de los sistemas de detección de intrusiones en redes IoT de borde, 2026.	**Problema general:** ¿Cómo mejora el aprendizaje federado la capacidad de detección de los sistemas de detección de intrusiones en redes IoT de borde, 2026? **Problemas específicos:** 1. ¿En qué medida el aprendizaje federado mejora el desempeño predictivo de los sistemas de detección de intrusiones en redes IoT de borde, 2026? 2. ¿En qué medida el aprendizaje federado mejora la generalización entre dispositivos de los sistemas de detección de intrusiones en redes IoT de borde, 2026? 3. ¿En qué medida el aprendizaje federado mejora la eficiencia del entrenamiento de los sistemas de detección de intrusiones en redes IoT de borde, 2026?	**Hipótesis general:** El aprendizaje federado mejora significativamente la capacidad de detección de los sistemas de detección de intrusiones en redes IoT de borde, 2026. **Hipótesis específicas:** H.E. 1: El aprendizaje federado mejora significativamente el desempeño predictivo de los sistemas de detección de intrusiones en redes IoT de borde, 2026, respecto a los modelos entrenados de forma aislada en cada dispositivo. H.E. 2: El aprendizaje federado mejora significativamente la generalización entre dispositivos de los sistemas de detección de intrusiones en redes IoT de borde, 2026, reduciendo la brecha frente al modelo centralizado. H.E. 3: El aprendizaje federado mejora significativamente la eficiencia del entrenamiento de los sistemas de detección de intrusiones en redes IoT de borde, 2026, al reducir el volumen de datos transmitido frente al esquema centralizado.	**Objetivo general:** **Desarrollar** un esquema de aprendizaje federado que mejore la capacidad de detección de los sistemas de detección de intrusiones en redes IoT de borde, 2026. **Objetivos específicos:** O.E. 1: **Analizar** en qué medida el aprendizaje federado mejora el desempeño predictivo de los sistemas de detección de intrusiones en redes IoT de borde, 2026. O.E. 2: **Evaluar** en qué medida el aprendizaje federado mejora la generalización entre dispositivos de los sistemas de detección de intrusiones en redes IoT de borde, 2026. O.E. 3: **Determinar** en qué medida el aprendizaje federado mejora la eficiencia del entrenamiento de los sistemas de detección de intrusiones en redes IoT de borde, 2026.	**Variable independiente:** Aprendizaje federado (Cuantitativo) **Dimensiones** - Estrategia de agregación - Heterogeneidad de los datos - Configuración del entrenamiento federado **Variable dependiente:** Capacidad de detección (Cuantitativo) **Dimensiones** - Desempeño predictivo (F1-score macro, tasa de falsos positivos) - Generalización entre dispositivos (brecha frente al modelo centralizado, F1 en ataques no vistos) - Eficiencia del entrenamiento (volumen de comunicación, tiempo local)	**Enfoque:** Cuantitativo **Tipo de investigación:** Aplicada **Nivel de investigación:** Explicativo (causal) **Diseño:** Experimental (experimento computacional controlado) con preprueba y posprueba, transversal **Población:** Flujos de tráfico de red de los dispositivos IoT/IIoT del testbed Edge-IIoTset, obtenidos de sus capturas PCAP crudas (Ferrag et al., 2022). **Muestra:** Muestreo no probabilístico por conveniencia (tráfico normal de cinco tipos de sensor y 13 tipos de ataque; 119 998 flujos), con submuestreo estratificado por clase. **Técnicas y Herramientas de Recolección de Datos:** **Técnicas:** 1- Observación estructurada; 2- Experimentación computacional (simulación de clientes federados). **Herramientas:** 1- Registro de observación estructurada; 2- Extractor propio de flujos bidireccionales en Python (dpkt); 3- Programa Python (NumPy, scikit-learn). **Técnicas de Análisis y Procesamiento de Datos:** **Análisis:** Estadística descriptiva (media ± desviación estándar en 5 semillas) e inferencial (prueba de rangos con signo de Wilcoxon, $\alpha = 0.05$). **Procesamiento:** Python (pandas, SciPy, Matplotlib).

REGISTRO DE OBSERVACIÓN ESTRUCTURADA

FICHA TÉCNICA DEL INSTRUMENTO DE INVESTIGACIÓN

Variable Evaluada	Variable Dependiente: Capacidad de detección de los sistemas de detección de intrusiones (Cuantitativa, Escala de Razón).
Objetivo del Instrumento	Medir y comparar cuantitativamente la capacidad de detección del IDS de cada cliente IoT entrenado de forma aislada (Pre-test) y mediante aprendizaje federado (Post-test), tomando como referencia el modelo centralizado.
Diseño Metodológico	Cuantitativo, Aplicado, Explicativo, Experimental (computacional), Transversal y Comparativo.
Técnica e Instrumento	Observación estructurada basada en el registro automatizado de métricas de evaluación (logs del experimento) y simulación de clientes federados.
Herramientas de Registro	Ficha de registro de observación estructurada automatizada mediante scripts en Python (NumPy, scikit-learn).
Unidad de Análisis / Observación	Modelo IDS de cada cliente (pasarela que concentra el tráfico de un tipo de dispositivo IoT, con tráfico etiquetado) evaluado sobre los flujos de tráfico de su conjunto de prueba.
Población y Muestra	Flujos de tráfico extraídos de las capturas PCAP crudas de Edge-IIoTset, seleccionados por conveniencia y estratificados por clase.

MATRIZ DEL REGISTRO DE OBSERVACIÓN ESTRUCTURADA (PRE-TEST VS. POST-TEST)

Instrucciones de Llenado: Esta ficha se aplica individualmente a cada ejecución del experimento (una por semilla aleatoria). En la columna Pre-Test se registran las métricas de los modelos entrenados de forma aislada solo con los datos locales de cada cliente. En la columna Post-Test se registran las métricas del modelo global obtenido mediante aprendizaje federado, evaluado sobre el conjunto de prueba de cada cliente. Los valores se obtienen con los scripts de evaluación y se completan tras ejecutar el experimento.

Código de ejecución:	EXP-2026-FL-001	**Estrategia de agregación:**	FedAvg / FedProx (μ = ____)
Partición de datos:	No-IID por tipo de dispositivo	**Evaluador / Investigador:**	Investigador

Cliente / Dimensión del Indicador Observado	EVALUACIÓN PRE-TEST (Modelo local aislado)	EVALUACIÓN POST-TEST (Aprendizaje federado)	DIFERENCIA ABSOLUTA (Δ)	VARIACIÓN RELATIVA (%)
CLIENTE 1: SENSOR DE TEMPERATURA Y HUMEDAD				
• Desempeño (F1 C1): F1-score macro (%)				
• Desempeño (FPR C1): Tasa de falsos positivos (%)				
• Generalización (ΔF1 C1): Brecha frente al modelo centralizado (pp)				
• Generalización (F1nv C1): F1 en ataques no vistos localmente (%)				
CLIENTE 2: SENSOR ULTRASÓNICO				
• Desempeño (F1 C2): F1-score macro (%)				
• Desempeño (FPR C2): Tasa de falsos positivos (%)				

Cliente / Dimensión del Indicador Observado	EVALUACIÓN PRE-TEST (Modelo local aislado)	EVALUACIÓN POST-TEST (Aprendizaje federado)	DIFERENCIA ABSOLUTA (Δ)	VARIACIÓN RELATIVA (%)
• Generalización (ΔF1 C2): Brecha frente al modelo centralizado (pp)				
• Generalización (F1nv C2): F1 en ataques no vistos localmente (%)				
CLIENTE 3: SENSOR DE NIVEL DE AGUA				
• Desempeño (F1 C3): F1-score macro (%)				
• Desempeño (FPR C3): Tasa de falsos positivos (%)				
• Generalización (ΔF1 C3): Brecha frente al modelo centralizado (pp)				
• Generalización (F1nv C3): F1 en ataques no vistos localmente (%)				
CLIENTE 4: SENSOR DE pH				
• Desempeño (F1 C4): F1-score macro (%)				
• Desempeño (FPR C4): Tasa de falsos positivos (%)				
• Generalización (ΔF1 C4): Brecha frente al modelo centralizado (pp)				
• Generalización (F1nv C4): F1 en ataques no vistos localmente (%)				
CLIENTE 5: SENSOR DE HUMEDAD DEL SUELO				
• Desempeño (F1 C5): F1-score macro (%)				
• Desempeño (FPR C5): Tasa de falsos positivos (%)				
• Generalización (ΔF1 C5): Brecha frente al modelo centralizado (pp)				
• Generalización (F1nv C5): F1 en ataques no vistos localmente (%)				
TOTALES CONSOLIDADOS DE LA EJECUCIÓN OBSERVADA				
1. F1-score macro promedio entre clientes (%)				
2. Tasa de falsos positivos promedio (%)				
3. Brecha promedio frente al modelo centralizado (pp)				
4. F1 promedio en ataques no vistos localmente (%)				

Cliente / Dimensión del Indicador Observado	EVALUACIÓN PRE-TEST (Modelo local aislado)	EVALUACIÓN POST-TEST (Aprendizaje federado)	DIFERENCIA ABSOLUTA (Δ)	VARIACIÓN RELATIVA (%)
5. Volumen de comunicación acumulado (MB)*				
6. Tiempo de entrenamiento local promedio por ronda (s)				

** Para este indicador, la columna Pre-Test registra el volumen que transmitiría el esquema centralizado (envío de los flujos de cada cliente al servidor), ya que el entrenamiento aislado no comunica datos.*

PROTOCOLO METODOLÓGICO

1. Fase Pre-Test (Línea de Base): Extracción de flujos bidireccionales (ventanas de 120 s) desde las capturas PCAP crudas de Edge-IIoTset con un extractor propio en Python (dpkt); etiquetado de los flujos de ataque según la IP atacante (IP ausente del tráfico normal) y partición no-IID por tipo de dispositivo. Cada cliente entrena un perceptrón multicapa (MLP) únicamente con sus datos locales y se calculan F1, FPR, ΔF1 y F1nv sobre su conjunto de prueba. En paralelo se entrena el mismo MLP con todos los datos (modelo centralizado) como cota superior de referencia.

2. Aplicación del Estímulo (Tratamiento): Entrenamiento federado de la misma arquitectura MLP con FedAvg y FedProx durante R rondas y E épocas locales, sin que los datos crudos salgan de cada cliente. Se registra el volumen de parámetros transmitido y el tiempo de entrenamiento por ronda.

3. Fase Post-Test: Evaluación del modelo global federado sobre el conjunto de prueba de cada cliente con las mismas métricas. El experimento se repite con cinco semillas aleatorias y las diferencias Pre-Test/Post-Test se contrastan con la prueba de rangos con signo de Wilcoxon ($\alpha = 0.05$).